

Применение искусственного интеллекта в физическом эксперименте

Шананин Василий Андреевич

старший преподаватель, ИСТАС, Московский государственный строительный университет (МГСУ), shananinva.infonom@gmail.com

Чаругин Виктор Максимович

профессор, профессор, доктор физико-математических наук, кафедра физики космоса, Московский педагогический государственный университет (МПГУ), charugin2010@mail.ru

Архипова Елена Михайловна

кандидат педагогических наук, доцент, кафедра общих математических естественнонаучных дисциплин, Московская финансовая юридическая академия (МФЮА), Arhipova.E@mfua.ru

Андрианова Анна Ивановна

студент математического факультета, Московский педагогический государственный университет (МПГУ), A.andrianova2001@yandex.ru

Обычно предсказание и моделирование физических явлений выполняется с помощью суперкомпьютеров и уравнений, основанных на законах физики. Несмотря на то, что эти уравнения очень универсальны, это не всегда означает, что они способны идеально воспроизводить отдельные характеристики отдельных явлений. Например, многие люди изучают физику движения маятника в средней школе. Реальный маятник будет отличаться от идеального, описанного формулами, из-за, например, производственных дефектов. Он не будет двигаться в соответствии с теорией и это приведет к ошибке в прогнозе моделирования. После большого успеха нейронные сети, специально разработанные для физических явлений, получили большое внимание. Гамильтоновы нейронные сети (hamiltonian neural networks) реализуют гамильтонов путь в нейросети и тем самым образуют «закон сохранения энергии» в физике. Однако это может быть невозможно в дискретном времени, что часто бывает при практическом обучении и вычислениях. Более того, в предыдущих моделях нейронных сетей не учитывались другие физические законы. В этом исследовании мы разберем принципы глубинной физической модели, основанной на энергии, которая допускает специфическую дифференциально-геометрическую структуру. Из этой структуры естественным образом вытекают закон сохранения энергии и закон сохранения массы. Чтобы обеспечить энергетическое поведение в дискретном времени, ученые предлагают алгоритм автоматической дискретной дифференцировки.

Ключевые слова: искусственный интеллект, физический эксперимент, применение, прогнозирование.

Исследовательская группа ученых разработала новую технологию на основе искусственного интеллекта, которую можно использовать для предсказания явлений, строго соблюдая физические законы, такие как закон сохранения энергии [1].

Модель применима к общим физическим явлениям, например механика Гамильтона, теория Ландау и моделирование фазового поля. Она включает гамильтоновы системы, состоящие из положения и импульса (так называемая естественная система, как, например, система масса-пружина), естественная система с трением, физическая система, полученная путем минимизации свободной энергии (например, фазовые переходы) и гамильтоновы уравнения, например, уравнения Максвелла [2].

Большинство исследований ранее были сосредоточены либо на одной из первых двух систем в особых условиях, либо они слишком распространены, чтобы моделировать законы сохранения.

Все уравнения можно записать в виде геометрических. И сосредоточив внимание на этом, исследователи переписали их, используя цифровые вычисления.

В разработанной ими методике, алгоритмы изучают функцию энергии на основе данных наблюдений за физическими явлениями, а затем генерируют уравнения движения в цифровом мире. Кроме того, нет необходимости переписывать эти уравнения движения для компьютерного моделирования [1].

Чтобы сделать это технически, разработано новую цифровую версию обратного распространения ошибки, используемую в машинном обучении с использованием автоматической дифференцировки. С помощью этого нового подхода можно сохранить физические законы, такие как закон сохранения энергии, в цифровом мире.

Использование этой новой методологии сделает возможным высокореliable прогнозы и поможет избежать возникновения неестественных повышений и понижений энергии, которые наблюдаются в традиционных моделях. Чтобы ввести физические законы в цифровой мир, также используются геометрические подходы, такие как симплектическая геометрия и риманова геометрия [4].

Это позволяет применять эту технику для предсказания более широкого круга явлений. Например, явление объединения двух капель в одну можно объяснить потерями энергии, которые происходят, когда они становятся единой каплей. Путем включения этого способа модель, разработанная в ходе этого исследования, была расширена для учета явлений рассеяния энергии, что позволило точно оценить уменьшение энергии. Это, например, структурная организация материалов, выращивание кристаллов и механика расширения трещин.

Существует алгоритм прогнозирования физических явлений Melvin, позволяющий по-новому проверить концептуальные основы квантовой механики. Последняя

попытка ученых в данном направлении [6] - созданный искусственный интеллект под названием THESEUS, повысил ставки: он на несколько порядков быстрее, чем Melvin, и люди могут легко анализировать его результаты.

Квантовый физик Нора Тишлер, которая была аспиранткой, работавшей с Цайлингером над несвязанной темой, когда Melvin проходил через её анализ, обратила внимание на эти разработки. "С самого начала было ясно, что [такого] эксперимента не было бы, если бы он не был обнаружен с помощью алгоритма", - говорит она [7].

Помимо генерации сложных запутанных состояний, установка, использующая более двух кристаллов с перекрывающимися путями, может быть использована для выполнения обобщенной формы экспериментов Цайлингера по квантовой интерференции 1994 года с двумя кристаллами.

Эрик Кавальканти из Университета Гриффита в Австралии впечатлен этой работой и относится к ней осмотрительно. "Эти методы машинного обучения представляют собой интересную разработку. Для ученого-человека, изучающего данные и интерпретирующего их, некоторые решения могут выглядеть как 'креативные' новые решения.

Но на данном этапе эти алгоритмы все еще далеки от того уровня, когда можно было бы сказать, что у них есть действительно новые идеи или новые концепции", - говорит он. "С другой стороны, я действительно думаю, что однажды они доберутся туда. Так что это маленькие шаги, но мы должны с чего-то начать". Штейнберг соглашается. "На данный момент это просто удивительные инструменты", - говорит он. "И, как и все лучшие инструменты, они уже позволяют нам делать некоторые вещи, которые мы, вероятно, не сделали бы без них" [8].

В статье, опубликованной в декабре в журнале *Astronomy & Astrophysics*, Шавински и его коллеги из ETH Zurich Деннис Турп и Се Чжан использовали генеративное моделирование для исследования физических изменений, которые претерпевают галактики по мере их эволюции. (Программное обеспечение, которое они использовали, обрабатывает скрытое пространство несколько иначе, чем то, как его обрабатывает генеративная состязательная сеть, так что технически это не GAN, хотя и похоже.) [8]

Их модель создавала искусственные наборы данных как способ проверки гипотез о физических процессах. Они спросили, например, как "гашение" звездообразования — резкое снижение скорости образования — связано с увеличением плотности окружающей среды галактики.

Для Шавински ключевой вопрос заключается в том, сколько информации о звездных и галактических процессах можно извлечь из одних только данных. "Давайте сотрем все, что мы знаем об астрофизике", - сказал он. "В какой степени мы могли бы заново открыть эти знания, просто используя сами данные?"

Сначала изображения галактик были сведены к их скрытому пространству; затем Шавински мог настроить один элемент этого пространства таким образом, чтобы он соответствовал определенному изменению окружающей среды галактики — например, плотности ее окружения.

Тогда он мог бы воссоздать галактику и посмотреть, какие обнаружились различия. "Итак, теперь у меня есть машина для генерации гипотез", - объяснил он. "Я могу

взять целую кучу галактик, которые изначально находятся в среде с низкой плотностью, и с помощью этого процесса заставить их выглядеть так, как будто они находятся в среде с высокой плотностью". Шавински, Турп и Чжан увидели, что по мере того, как галактики переходят из среды с низкой плотностью в среду с высокой плотностью, они становятся более красными по цвету, а их звезды становятся более сосредоточенными в центре [8]. По словам Шавински, это соответствует существующим наблюдениям за галактиками. Вопрос в том, почему это так.

Следующий шаг, по словам Шавински, еще не автоматизирован: Я должен войти как человек и сказать: «Хорошо, какая физика может объяснить этот эффект?» Для рассматриваемого процесса есть два правдоподобных объяснения: возможно, галактики становятся краснее при высокой плотности среды, потому что они содержат больше пыли, или, возможно, они становятся краснее из-за снижения звездообразования (другими словами, их звезды, как правило, старше).

С помощью генеративной модели обе идеи могут быть проверены: элементы в скрытом пространстве, связанные с запыленностью и скоростью звездообразования, изменяются, чтобы увидеть, как это влияет на цвет галактик. "И ответ ясен", - сказал Шавински. Более красные галактики - это "те, где звездообразование прекратилось, а не те, где пыль изменилась. Так что мы должны поддержать это объяснение" [9].

Этот подход связан с традиционным моделированием, но имеет существенные отличия. Моделирование "по сути, основано на предположениях", - сказал Шавински. "Подход заключается в том, чтобы сказать: "Я думаю, что знаю, каковы основные физические законы, которые порождают все, что я вижу в системе. Итак, у меня есть рецепт звездообразования, у меня есть рецепт того, как ведет себя темная материя, и так далее. Я поместил туда все свои гипотезы и запустил симуляцию. И тогда я спрашиваю: похоже ли это на реальность?" По его словам, то, что он сделал с генеративным моделированием, "в некотором смысле прямо противоположно симуляции. Мы ничего не знаем; мы не хотим ничего предполагать. Мы хотим, чтобы сами данные подсказывали нам, что может происходить".

Очевидный успех генеративного моделирования в подобном исследовании, очевидно, не означает, что астрономы и аспиранты были уволены, но, по-видимому, это представляет собой сдвиг в степени, в которой изучение астрофизических объектов и процессов может быть достигнуто с помощью искусственной системы, у которой под рукой немного больше, чем у компьютера: огромный массив данных. "Это не полностью автоматизированная наука, но она демонстрирует, что мы способны, по крайней мере частично, создавать инструменты, которые делают научный процесс автоматическим", - сказал Шавински.

Генеративное моделирование, несомненно, обладает огромной силой, но вопрос о том, действительно ли оно представляет собой новый подход к науке, остается открытым для обсуждения.

Для Дэвида Хогга, космолога из Нью-Йоркского университета и Института Флэтайрона (который, как и Quanta, финансируется Фондом Саймонса), эта техника впечатляет, но в конечном счете просто очень сложный способ извлечения закономерностей из данных - что астрономы и делали на протяжении веков. Другими словами, это продвинутая форма наблюдения плюс анализ.

Собственная работа Хогга, как и работа Шавински, в значительной степени опирается на искусственный интеллект; он использовал нейронные сети для классификации звезд в соответствии с их спектрами и для определения других физических характеристик звезд с использованием моделей, основанных на данных.

Но он считает свою работу, как и работу Шавински, проверенной наукой. "Я не думаю, что это третий путь", - сказал он недавно. "Я просто думаю, что мы, как сообщество, становимся гораздо более изощренными в том, как мы используем данные. В частности, мы становимся намного лучше в сравнении данных с данными. Но, на мой взгляд, работа все еще находится в режиме наблюдения".

Литература

1. Battaglia, P., Pascanu, R., Lai, M., Rezende, D. J., and Kavukcuoglu, K. (2016). "Interaction networks for learning about objects, relations and physics," in *Advances in Neural Information Processing Systems*, (Long Beach, CA), 4502–10.
2. Battaglia, P. W., Hamrick, J. B., Bapst, V., Sanchez-Gonzalez, A., Zambaldi, V., Malinowski, M., et al. (2018). Relational inductive biases, deep learnin
3. Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. New York, NY: Springer.
4. Champion, K., Zheng, P., Aravkin, A. Y., Brunton, S. L., and Kutz, J. N. (2019). A unified sparse optimization framework to learn parsimonious physics-informed models from data. *arXiv 1906.10612*.
5. Chang, M. B., Ullman, T., Torralba, A., and Tenenbaum, J. B. (2016). A compositional object-based approach to learning physical dynamics. *arXiv 1612.00341*.
6. Dam, M., Brøns, M., Juul Rasmussen, J., Naulin, V., and Hesthaven, J. S. (2017). Sparse identification of a predator-prey system from simulation data of a convection model. *Phys. Plasmas* 24:022310. doi: 10.1063/1.4977057
7. Falconer, I. (2017). No actual measurement...was required: Maxwell and cavendish's null method for the inverse square law of electrostatics. *Stud. Hist. Philos. Sci. A* 65, 74–86. doi: 10.1016/j.shpsa.2017.05.001
8. Goff, J. E. (2013). A review of recent research into aerodynamics of sport projectiles. *Sports Eng.* 16, 137–154. doi: 10.1007/s12283-013-0117-z
9. Hoffmann, M., Fröhner, C., and Noé, F. (2019). Reactive SINDy: discovering governing reactions from concentration data. *J. Chem. Phys.* 150:025101. doi: 10.1063/1.5066099
10. Kaiser, E., Kutz, J. N., and Brunton, S. L. (2018). Sparse identification of nonlinear dynamics for model predictive control in the low-data limit. *Proc. R. Soc. Lond. A* 474:2219. doi: 10.1098/rspa.2018.0335
11. Lai, Z., and Nagarajaiah, S. (2019). Sparse structural system identification method for nonlinear dynamic systems with hysteresis/inelastic behavior. *Mech. Syst. Signal Process.* 117, 813–42. doi: 10.1016/j.ymssp.2018.08.033
12. Mangan, N. M., Brunton, S. L., Proctor, J. L., and Kutz, J. N. (2016). Inferring biological networks by sparse identification of nonlinear dynamics. *IEEE Trans. Mol. Biol. Multiscale Commun.* 2, 52–63. doi: 10.1109/TMBMC.2016.2633265
13. Raissi, M. (2018). Deep hidden physics models: Deep learning of nonlinear partial differential equations. *J. Mach. Learn. Res.* 19, 932–55. Available online at: <http://jmlr.org/papers/v19/18-046.html>.

14. Rudy, S., Alla, A., Brunton, S. L., and Kutz, J. N. (2019). Data-driven identification of parametric partial differential equations. *SIAM J. Appl. Dyn. Syst.* 18, 643–60. doi: 10.1137/18M1191944

15. Schaeffer, H., Tran, G., and Ward, R. (2018). Extracting sparse high-dimensional dynamics from limited data. *SIAM J. Appl. Math.* 78, 3279–95. doi: 10.1137/18M116798X

Application of artificial intelligence in a physical experiment

Shananin V.A., Charugin V.M., Arkhipova E.M., Andrianova A.I.

Moscow State University of Civil Engineering (MGSU), Moscow State Pedagogical University (MPGU), Moscow Financial Law Academy (MFLA)

JEL classification: C10, C50, C60, C61, C80, C87, C90

Usually, the prediction and modeling of physical phenomena is performed using supercomputers and equations based on the laws of physics. Despite the fact that these equations are very universal, this does not always mean that they are able to perfectly reproduce the individual characteristics of individual phenomena. For example, many people study the physics of pendulum motion in high school. A real pendulum will differ from the ideal one described by formulas, due to, for example, manufacturing defects. It will not move according to the theory and this will lead to an error in the simulation prediction. After great success, neural networks specially designed for physical phenomena have received a lot of attention. Hamiltonian neural networks implement the Hamiltonian path in neural networks and thereby form the "law of conservation of energy" in physics. However, this may not be possible in discrete time, which is often the case with practical training and computing. Moreover, previous models of neural networks did not take into account other physical laws. In this study, we will analyze the principles of a deep physical model based on energy, which admits a specific differential geometric structure. The law of conservation of energy and the law of conservation of mass naturally follow from this structure. To ensure energy behavior in discrete time, scientists propose an algorithm for automatic discrete differentiation.

Keywords: artificial intelligence, physical experiment, application, forecasting.

References

1. Battaglia, P., Pascanu, R., Lai, M., Rezende, D. J., and Kavukcuoglu, K. (2016). "Interaction networks for learning about objects, relations and physics," in *Advances in Neural Information Processing Systems*, (Long Beach, CA), 4502–10.
2. Battaglia, P. W., Hamrick, J. B., Bapst, V., Sanchez-Gonzalez, A., Zambaldi, V., Malinowski, M., et al. (2018). Relational inductive biases, deep learnin
3. Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. New York, NY: Springer.
4. Champion, K., Zheng, P., Aravkin, A. Y., Brunton, S. L., and Kutz, J. N. (2019). A unified sparse optimization framework to learn parsimonious physics-informed models from data. *arXiv 1906.10612*.
5. Chang, M. B., Ullman, T., Torralba, A., and Tenenbaum, J. B. (2016). A compositional object-based approach to learning physical dynamics. *arXiv 1612.00341*.
6. Dam, M., Brøns, M., Juul Rasmussen, J., Naulin, V., and Hesthaven, J. S. (2017). Sparse identification of a predator-prey system from simulation data of a convection model. *Phys. Plasmas* 24:022310. doi: 10.1063/1.4977057
7. Falconer, I. (2017). No actual measurement...was required: Maxwell and cavendish's null method for the inverse square law of electrostatics. *Stud. Hist. Philos. Sci. A* 65, 74–86. doi: 10.1016/j.shpsa.2017.05.001
8. Goff, J. E. (2013). A review of recent research into aerodynamics of sport projectiles. *Sports Eng.* 16, 137–154. doi: 10.1007/s12283-013-0117-z
9. Hoffmann, M., Fröhner, C., and Noé, F. (2019). Reactive SINDy: discovering governing reactions from concentration data. *J. Chem. Phys.* 150:025101. doi: 10.1063/1.5066099
10. Kaiser, E., Kutz, J. N., and Brunton, S. L. (2018). Sparse identification of nonlinear dynamics for model predictive control in the low-data limit. *Proc. R. Soc. Lond. A* 474:2219. doi: 10.1098/rspa.2018.0335
11. Lai, Z., and Nagarajaiah, S. (2019). Sparse structural system identification method for nonlinear dynamic systems with hysteresis/inelastic behavior. *Mech. Syst. Signal Process.* 117, 813–42. doi: 10.1016/j.ymssp.2018.08.033
12. Mangan, N. M., Brunton, S. L., Proctor, J. L., and Kutz, J. N. (2016). Inferring biological networks by sparse identification of nonlinear dynamics. *IEEE Trans. Mol. Biol. Multiscale Commun.* 2, 52–63. doi: 10.1109/TMBMC.2016.2633265
13. Raissi, M. (2018). Deep hidden physics models: Deep learning of nonlinear partial differential equations. *J. Mach. Learn. Res.* 19, 932–55. Available online at: <http://jmlr.org/papers/v19/18-046.html>.
14. Rudy, S., Alla, A., Brunton, S. L., and Kutz, J. N. (2019). Data-driven identification of parametric partial differential equations. *SIAM J. Appl. Dyn. Syst.* 18, 643–60. doi: 10.1137/18M1191944
15. Schaeffer, H., Tran, G., and Ward, R. (2018). Extracting sparse high-dimensional dynamics from limited data. *SIAM J. Appl. Math.* 78, 3279–95. doi: 10.1137/18M116798X